INFORME DE PRÁCTICA · MACHINE LEARNING

Machine Learning No Supervisado

Clustering y reducción de dimensionalidad con Scikit-learn

AUTOR

Jerson Baquero Cháves

PROGRAMA

Especialización en Inteligencia Artificial · Universidad de Cundinamarca

MATERIA

Machine Learning

FECHA

Octubre de 2026

REPOSITORIO DE GITHUB

https://github.com/Jerson09/R1-A3-S12-INFORME-DE-TRABAJO-ML-NO-SUPERVISADO

NOTEBOOK EN GOOGLE COLAB

https://colab.research.google.com/drive/1jAkSppWIAiR-vRKjjZeTt6zG1zhsef0L

Introducción

Imagina que te entregan una caja con cientos de fotos mezcladas y te piden ordenarlas, pero nadie te dice cómo. Probablemente las agruparías por parecido: fotos de playa por un lado, de cumpleaños por otro. Eso es, en esencia, el **aprendizaje no supervisado**: un computador que encuentra grupos y patrones por sí solo, sin que nadie le diga la respuesta correcta (Hastie et al., 2009).

En este informe se prueban dos familias de técnicas con datos reales: **agrupar** elementos parecidos (clustering, con los métodos K-means y jerárquico) y **resumir** mucha información en pocos datos (reducción de dimensionalidad, con los métodos PCA y SVD). Todo se programó en Python dentro de Google Colab, con las librerías Scikit-learn (Pedregosa et al., 2011) para los cálculos y Matplotlib (Hunter, 2007) para los gráficos. El notebook completo está disponible en Google Colab y en el repositorio de GitHub indicados en la portada.

Mini glosario: palabras clave en lenguaje simple

Término	Qué significa en palabras simples
Dato / variable	Una característica que se mide. Por ejemplo, de un vino: su acidez o su color.
Algoritmo	Una receta paso a paso que sigue el computador para resolver un problema.
Cluster (grupo)	Conjunto de elementos que se parecen entre sí más que con el resto.
Dimensionalidad	Cuántas características describen cada elemento. Más características = más dimensiones.
Estandarizar	Poner todas las medidas en una escala comparable, como convertir todo a la misma moneda.
Silueta	Nota de 0 a 1 que indica qué tan bien separados están los grupos (más cerca de 1 es mejor).
ARI	Nota que compara los grupos del computador con los grupos reales: 1 es coincidencia perfecta y 0 es como tirar una moneda al aire.
Varianza explicada	Qué porcentaje de la información original se conserva después de resumir los datos.

1. Los conceptos, explicados fácil

Aprendizaje no supervisado

En el aprendizaje *supervisado* se le muestran al computador ejemplos con la respuesta ("esta foto es un gato") para que aprenda. En el *no supervisado* no hay respuestas: es como separar la ropa para lavar sin etiquetas, donde igual terminas haciendo montones de colores claros y oscuros. Sirve para descubrir segmentos de clientes, explorar datos nuevos o simplificar información muy grande.

K-means: repartir en grupos según la cercanía

Imagina que debes repartir a los asistentes de una fiesta en *k* mesas según qué tan parecidos son. K-means pone un "centro" en cada mesa, asigna a cada persona al centro más cercano, mueve el centro hacia el medio de su grupo y repite hasta que nadie cambia de mesa (Arthur y Vassilvitskii, 2007). Su limitación es que hay que decidir cuántas mesas (*k*) antes de empezar. Para elegirlas se usan dos ayudas: el **método del codo**, que busca el punto donde agregar más grupos deja de mejorar mucho el resultado, y la **silueta** (Rousseeuw, 1987), que califica qué tan bien separados quedaron los grupos.

Clustering jerárquico: un árbol genealógico de datos

Aquí se empieza con cada elemento solo y se van uniendo los más parecidos, como familias que se juntan en una familia más grande, hasta formar un único árbol. Para unir se usa el criterio de Ward (1963), que junta los grupos que menos "desordenan" el resultado. El árbol se dibuja en un **dendrograma**: cortándolo a cierta altura se obtiene el número de grupos deseado, sin decidirlo de antemano.

PCA y SVD: resumir sin perder lo importante

Piensa en la sombra de un objeto: aunque el objeto es 3D, la sombra en la pared (2D) conserva su forma general. PCA hace algo parecido con los datos: reduce muchas características a unas pocas "características resumen" llamadas **componentes principales**, escogidas para conservar la mayor cantidad de información posible (Jolliffe y Cadima, 2016). La **SVD** es una técnica matemática muy parecida y más rápida con datos enormes (Halko et al., 2011); cuando los datos están ordenados alrededor de cero, ambas dan casi lo mismo. Resumir es útil para dibujar datos complejos en un gráfico plano, ahorrar espacio y eliminar ruido.

2. ¿Cómo se hizo? Metodología

Se usaron dos conjuntos de datos que ya vienen incluidos en Scikit-learn:

Vinos (Wine): 178 vinos descritos con 13 medidas químicas (alcohol, acidez, fenoles, etc.). Provienen de 3 tipos de uva, pero el computador no lo sabe.

Dígitos (Digits): 1.797 imágenes pequeñas (8×8 píxeles) de números escritos a mano del 0 al 9; cada imagen se describe con 64 valores, uno por píxel.

Las respuestas reales (el tipo de uva o el número dibujado) **no** se le dieron al computador. Se usaron solo al final, como un "solucionario", para comprobar qué tan bien lo hizo, usando la nota ARI explicada en el glosario (Hubert y Arabie, 1985). En los vinos se estandarizaron las medidas, porque unas se miden en números grandes y otras en pequeños, y sin ese paso las grandes tendrían más peso sin merecerlo. Todos los experimentos son repetibles porque se fijó una semilla aleatoria (42).

3. Resultados y análisis

3.1 K-means sobre los vinos

En palabras simples

Se le pidió al computador separar los vinos en 2, 3, 4... hasta 8 grupos y se midió qué tan buena fue cada opción.

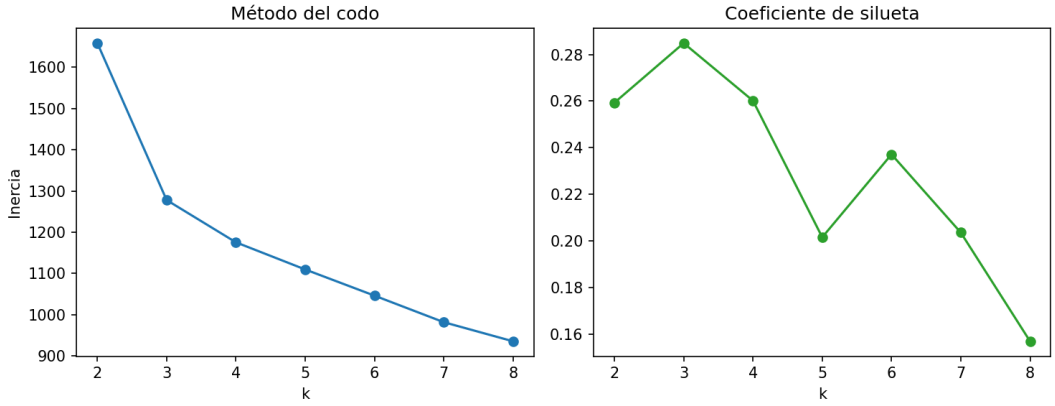
TABLA 1

Qué tan compactos (inercia, menor es mejor) y separados (silueta, mayor es mejor) quedan los grupos según su cantidad

Grupos (k)	2	3	4	5	6	7	8
Inercia	1658,8	1277,9	1175,4	1109,5	1046,0	981,6	935,2
Silueta	0,259	0,285	0,260	0,202	0,237	0,204	0,157

FIGURA 1

Método del codo (izquierda) y silueta (derecha) para escoger la cantidad de grupos



La línea de la izquierda baja de forma suave, sin un "codo" muy claro, pero la silueta de la derecha tiene su punto más alto con **3 grupos** (0,285). Eso coincide con la realidad: los vinos provienen de 3 tipos de uva. Con 3 grupos, K-means obtuvo un ARI de 0,897, es decir, una coincidencia muy alta con la verdad: de 178 vinos, solo 6 quedaron en un grupo distinto al de su tipo (todos del tipo 1; los tipos 0 y 2 se agruparon sin errores). Una silueta de 0,285 se considera moderada: los grupos se tocan un poco en los bordes, algo normal con datos reales.

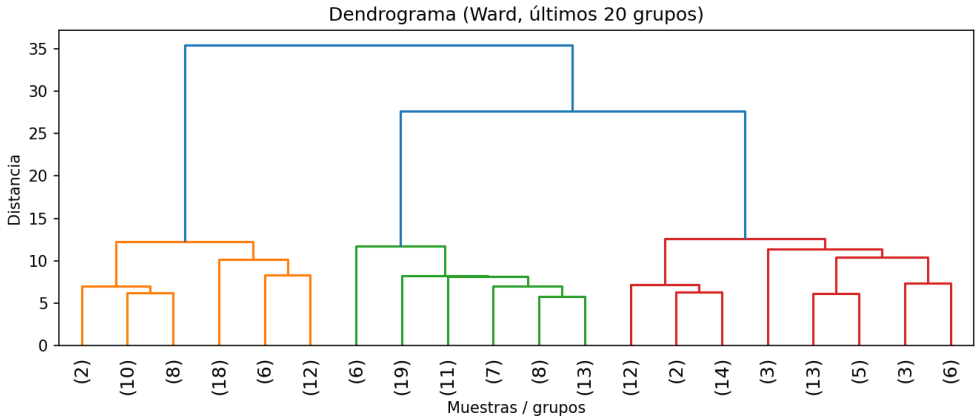
Hallazgo clave

La silueta máxima en k = 3 coincide con los tres tipos de uva reales; K-means logra un ARI de 0,897 y solo 6 de 178 vinos quedan mal agrupados.

3.2 Clustering jerárquico sobre los vinos

FIGURA 2

Dendrograma (árbol) de los vinos, truncado a los últimos 20 grupos



El árbol muestra tres ramas grandes y bien separadas: las uniones de mayor distancia ocurren entre ellas. Esto confirma de otra manera que tiene sentido hablar de 3 grupos. Al cortar el árbol en 3, el método jerárquico obtuvo una silueta de 0,277 y un ARI de 0,790, algo menor que K-means (0,897). Ambos métodos coinciden bastante entre sí (ARI = 0,853). Una posible razón es que el método jerárquico no corrige una unión una vez hecha, mientras que K-means sigue ajustando sus centros; a cambio, el árbol muestra cómo se relacionan los grupos, algo que K-means no ofrece.

TABLA 2

Comparación de los métodos de agrupación en los vinos (3 grupos)

Método	Silueta	ARI (¿acertó?)
K-means	0,285	0,897
Jerárquico (Ward)	0,277	0,790
K-means sobre 2 componentes	—	0,895

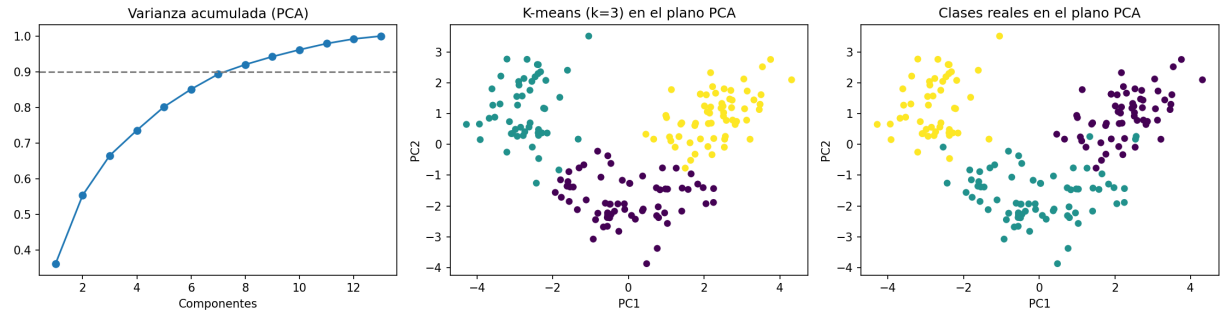
3.3 Resumir los vinos con PCA

En palabras simples

Se resumieron las 13 medidas de cada vino en solo 2 "medidas resumen" para poder dibujarlos en un plano.

FIGURA 3

Información conservada al resumir (izquierda), grupos de K-means (centro) y tipos reales de uva (derecha)



Las dos primeras medidas resumen conservan el 36,2 % y el 19,2 % de la información, en total un 55,4 %; para llegar a más del 90 % se necesitan 8. Aun así, en el gráfico plano los tres tipos de uva se ven separados, y al agrupar solo con esas 2 medidas K-means acierta casi igual (ARI de 0,895) que usando las 13 originales (0,897). La primera medida resumen está dominada por flavonoides (0,423), fenoles totales (0,395) y la prueba OD280/OD315 (0,376), todas relacionadas con compuestos fenólicos del vino.

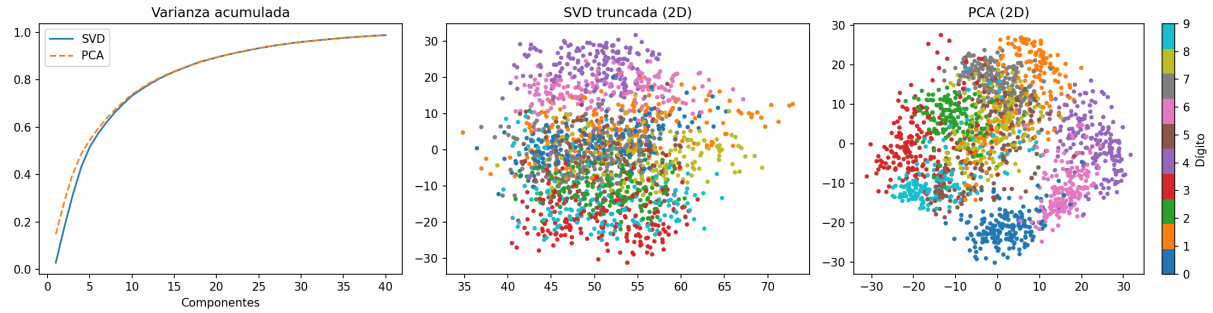
Hallazgo clave

Con solo 2 medidas resumen en lugar de 13, K-means conserva casi toda su precisión (ARI de 0,895 frente a 0,897).

3.4 Resumir imágenes de dígitos con SVD y PCA

FIGURA 4

Información conservada (izquierda) y dígitos dibujados en 2 dimensiones con SVD (centro) y PCA (derecha)



Con 10 medidas resumen, SVD conserva el 73,2 % de la información y PCA el 73,8 %; con 40, ambas llegan al 98,8 %. La diferencia es mínima porque en estas imágenes los valores ya están bastante centrados, y por eso ambas técnicas se comportan casi igual. En el gráfico de 2 dimensiones se ven nubes por dígito, con algo de mezcla entre números de forma parecida (como 3, 5 y 8), lo esperable al comprimir 64 datos en solo 2.

TABLA 3

Agrupar los dígitos en 10 grupos con las imágenes completas y con las imágenes resumidas

Datos usados	Medidas por imagen	Silueta	ARI
Originales	64	0,182	0,667
Resumidos con SVD	20	0,212	0,666

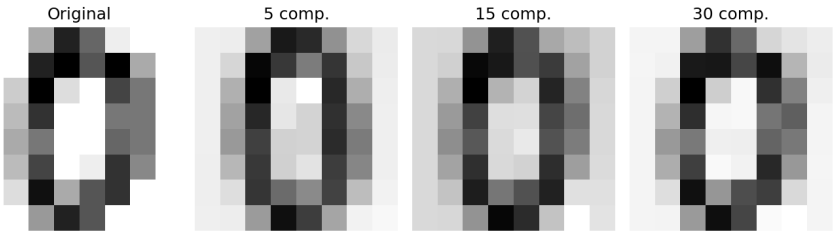
Resumir de 64 a 20 medidas dejó el acierto prácticamente igual (ARI 0,667 frente a 0,666) y mejoró un poco la silueta (de 0,182 a 0,212), con 69 % menos datos. Es probable que lo descartado fuera sobre todo "ruido", así que resumir hace el trabajo más rápido y barato sin perder calidad.

Hallazgo clave

Pasar de 64 a 20 medidas con SVD (69 % menos datos) mantiene el ARI en 0,667 y mejora la silueta de 0,182 a 0,212.

FIGURA 5

Un mismo dígito reconstruido con 5, 15 y 30 medidas resumen, comparado con el original



La reconstrucción muestra el efecto de forma visual: a medida que se conservan más medidas resumen, la imagen se parece cada vez más al original, y con 30 es casi idéntica.

¿Para qué sirve esto en la vida real?

Las mismas ideas se usan fuera del salón de clase: una tienda puede agrupar a sus clientes según sus hábitos de compra para ofrecerles promociones distintas; un medio digital puede agrupar noticias por tema; una empresa puede comprimir fotos o datos de sensores para ahorrar espacio; y un analista puede dibujar en un gráfico sencillo datos de decenas de columnas para entenderlos de un vistazo.

Conclusiones

1. Preparar los datos importa. Poner las medidas de los vinos en una misma escala fue clave para que ninguna pesara de más.

2. Se pueden encontrar grupos sin respuestas previas. Con la silueta se detectaron correctamente 3 grupos, y K-means (ARI 0,897) superó al método jerárquico (ARI 0,790) en este caso; el árbol del jerárquico aportó una mirada complementaria.

3. Resumir casi no cuesta precisión. PCA y SVD redujeron mucho los datos con una pérdida mínima, y además permitieron dibujarlos en gráficos sencillos.

4. Las notas se leen en conjunto. Una silueta moderada no impidió una coincidencia alta con la realidad.

Limitaciones y siguientes pasos. Se usaron conjuntos pequeños y ordenados, y PCA/SVD solo capturan relaciones "rectas". Como trabajo futuro se podrían probar otros métodos, como DBSCAN, t-SNE o UMAP.

Repositorio de GitHub

Repositorio:
https://github.com/Jerson09/R1-A3-S12-INFORME-DE-TRABAJO-ML-NO-SUPERVISADO

Notebook en Google Colab:
https://colab.research.google.com/drive/1jAkSppWIAiR-vRKjjZeTt6zG1zhsef0L

Referencias

Arthur, D., y Vassilvitskii, S. (2007). k-means++: The advantages of careful seeding. *Proceedings of the 18th Annual ACM-SIAM Symposium on Discrete Algorithms*, 1027–1035.

Halko, N., Martinsson, P.-G., y Tropp, J. A. (2011). Finding structure with randomness: Probabilistic algorithms for constructing approximate matrix decompositions. *SIAM Review, 53*(2), 217–288. https://doi.org/10.1137/090771806

Hastie, T., Tibshirani, R., y Friedman, J. (2009). *The elements of statistical learning: Data mining, inference, and prediction* (2.ª ed.). Springer.

Hubert, L., y Arabie, P. (1985). Comparing partitions. *Journal of Classification, 2*(1), 193–218. https://doi.org/10.1007/BF01908075

Hunter, J. D. (2007). Matplotlib: A 2D graphics environment. *Computing in Science & Engineering, 9*(3), 90–95. https://doi.org/10.1109/MCSE.2007.55

Jolliffe, I. T., y Cadima, J. (2016). Principal component analysis: A review and recent developments. *Philosophical Transactions of the Royal Society A, 374*(2065), 20150202. https://doi.org/10.1098/rsta.2015.0202

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., y Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research, 12*, 2825–2830.

Rousseeuw, P. J. (1987). Silhouettes: A graphical aid to the interpretation and validation of cluster analysis. *Journal of Computational and Applied Mathematics, 20*, 53–65. https://doi.org/10.1016/0377-0427(87)90125-7

Ward, J. H. (1963). Hierarchical grouping to optimize an objective function. *Journal of the American Statistical Association, 58*(301), 236–244. https://doi.org/10.1080/01621459.1963.10500845