Machine Learning No Supervisado: Clustering y Reducción de Dimensionalidad con Scikit-learn

Jerson Baquero Cháves
Especialización en Inteligencia Artificial
Universidad de Cundinamarca
Machine Learning
Octubre de 2026

Repositorio:
https://github.com/Jerson09/R1-A3-S12-INFORME-DE-TRABAJO-ML-NO-SUPERVISADO

Introducción

El aprendizaje no supervisado trabaja con datos sin etiquetas y busca descubrir estructura oculta en ellos, ya sea agrupando observaciones similares (clustering) o representando los datos con menos variables (reducción de dimensionalidad) (Hastie et al., 2009). Este informe implementa en Google Colab dos algoritmos de clustering, K-means y clustering jerárquico aglomerativo, y dos métodos de reducción de dimensionalidad, el análisis de componentes principales (PCA) y la descomposición en valores singulares truncada (SVD), usando Scikit-learn (Pedregosa et al., 2011) y Matplotlib (Hunter, 2007). Los notebooks completos están disponibles en el repositorio de GitHub indicado en la portada.

1. Fundamentos conceptuales

Machine Learning no supervisado

A diferencia del aprendizaje supervisado, no existe una variable objetivo que guíe el entrenamiento: el algoritmo debe encontrar patrones solo a partir de la geometría de los datos. Sus usos más comunes son la segmentación, la exploración de datos, la visualización de espacios de alta dimensión y el preprocesamiento para otros modelos.

K-means

K-means divide los datos en k grupos minimizando la inercia, es decir, la suma de las distancias cuadráticas de cada punto al centroide de su grupo. Alterna entre asignar puntos al centroide más cercano y recalcular los centroides; su resultado depende de la inicialización, por lo que se emplea k-means++ (Arthur y Vassilvitskii, 2007) con varias repeticiones. Requiere fijar k de antemano y es sensible a la escala de las variables. Para elegir k se usan el método del codo y el coeficiente de silueta (Rousseeuw, 1987), que mide qué tan cohesionado y separado está cada grupo (valores cercanos a 1 son mejores).

Clustering jerárquico

El enfoque aglomerativo parte de cada observación como un grupo y fusiona sucesivamente los dos grupos más cercanos. Con el criterio de Ward (1963) se fusiona el par que menos incrementa la varianza intra-grupo. El resultado se representa en un dendrograma, que permite elegir el número de grupos cortando el árbol a una altura dada sin fijar k de antemano.

PCA y SVD

PCA proyecta los datos sobre ejes ortogonales (componentes principales) que capturan la mayor varianza posible (Jolliffe y Cadima, 2016). Se calcula sobre datos centrados mediante la SVD de la matriz de datos, $X = U\Sigma V^T$. La SVD truncada (*TruncatedSVD*) aplica la misma descomposición sin centrar los datos y mediante algoritmos aleatorizados eficientes (Halko et al., 2011), por lo que también funciona con matrices dispersas. Cuando los datos ya están centrados,

ambos métodos coinciden.

2. Metodología

Se utilizaron dos conjuntos de datos incluidos en Scikit-learn: **Wine** (178 vinos, 13 variables químicas, 3 cultivares) para clustering y PCA, y **Digits** (1.797 imágenes de 8×8 píxeles, 64 variables, 10 dígitos) para SVD y para evaluar el efecto de la reducción sobre el clustering. Las etiquetas reales no se usaron en el entrenamiento; solo se emplearon al final para validar los grupos con el índice de Rand ajustado (ARI; Hubert y Arabie, 1985), donde 1 indica coincidencia perfecta y 0 un resultado equivalente al azar. En Wine se estandarizaron las variables con *StandardScaler* porque sus escalas son muy distintas. Todos los experimentos usan *random_state* = 42.

3. Resultados y análisis

3.1 K-means sobre Wine

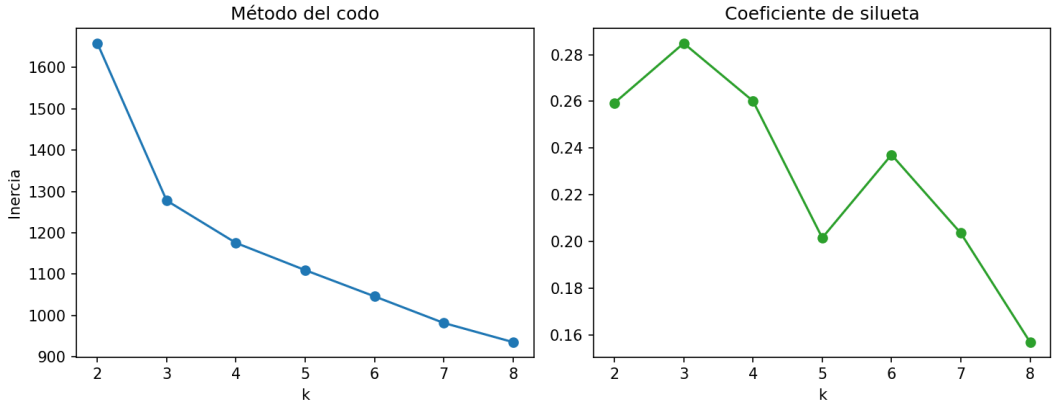
Tabla 1

Inercia y coeficiente de silueta de K-means según k (Wine estandarizado)

k	2	3	4	5	6	7	8
Inercia	1658,8	1277,9	1175,4	1109,5	1046,0	981,6	935,2
Silueta	0,259	0,285	0,260	0,202	0,237	0,204	0,157

Figura 1

Método del codo y coeficiente de silueta para K-means



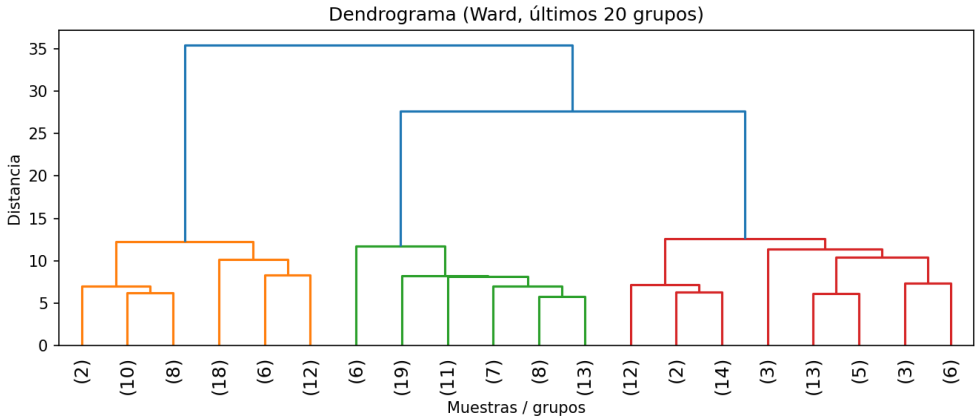
La inercia disminuye de forma continua y el codo no es muy marcado, pero el coeficiente de silueta alcanza su máximo en $k = 3$ (0,285), lo que coincide con los tres cultivares reales. Con $k = 3$, K-means obtuvo un ARI de 0,897: de 178 vinos, solo 6 quedaron en un grupo distinto al de su clase mayoritaria (todos pertenecientes a la clase 1; las clases 0 y 2 se recuperaron sin errores). Un silueta de 0,285 es moderado, lo que indica que los grupos se solapan parcialmente, algo esperable

en datos químicos reales.

3.2 Clustering jerárquico sobre Wine

Figura 2

Dendrograma con enlace de Ward (truncado a los últimos 20 grupos)



El dendrograma muestra tres ramas principales claramente separadas por las fusiones de mayor distancia, consistente con $k = 3$. El modelo jerárquico con 3 grupos obtuvo una silueta de 0,277 y un ARI de 0,790, algo inferior al de K-means (0,897). Ambos métodos coinciden bastante entre sí (ARI = 0,853). La diferencia puede explicarse porque el método jerárquico no reasigna puntos una vez fusionados, mientras que K-means refina iterativamente los centroides; en cambio, el dendrograma aporta información de la estructura anidada que K-means no ofrece.

Tabla 2

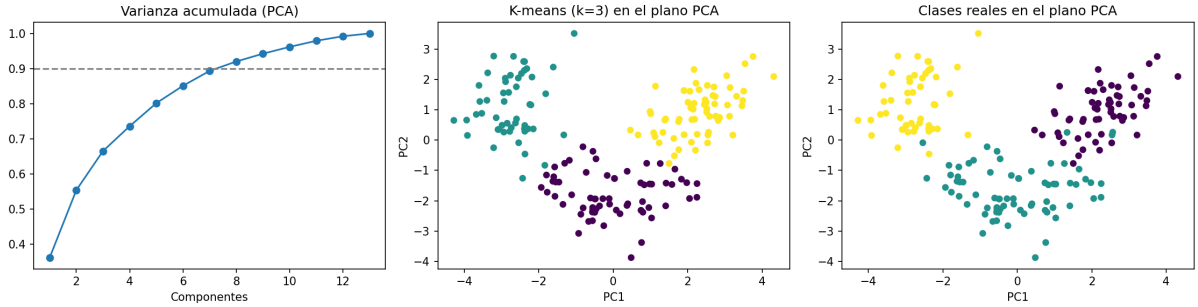
Comparación de algoritmos de clustering en Wine (k = 3)

Algoritmo	Silueta	ARI vs. clases reales
K-means	0,285	0,897
Jerárquico (Ward)	0,277	0,790
K-means sobre 2 PC	—	0,895

3.3 PCA sobre Wine

Figura 3

Varianza acumulada de PCA y proyección 2D coloreada por clusters de K-means y por clases reales

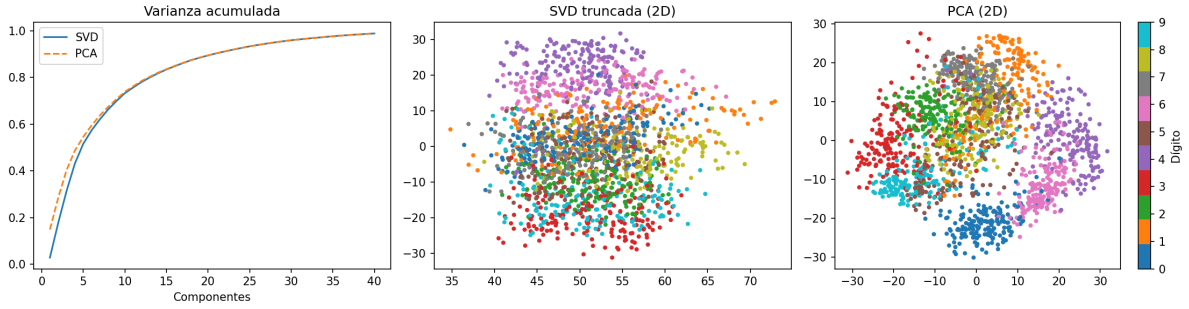


Las dos primeras componentes explican el 36,2 % y el 19,2 % de la varianza (55,4 % en total), y se necesitan 8 componentes para superar el 90 %. Aun así, el plano PC1–PC2 separa visualmente las tres clases, y el clustering de K-means sobre solo 2 componentes alcanza un ARI de 0,895, prácticamente igual al obtenido con las 13 variables (0,897). Esto muestra que la estructura de grupos está concentrada en pocas direcciones. PC1 está dominada por flavonoides (0,423), fenoles totales (0,395) y OD280/OD315 (0,376), es decir, por el contenido fenólico del vino.

3.4 SVD y PCA sobre Digits

Figura 4

Varianza acumulada de SVD truncada y PCA, y proyecciones 2D de Digits coloreadas por dígito



Con 10 componentes, la SVD truncada explica el 73,2 % de la varianza y PCA el 73,8 %; con 40 componentes ambas llegan al 98,8 %. La diferencia es mínima porque en Digits los datos tienen media casi constante por píxel, de modo que no centrar (SVD) o centrar (PCA) cambia poco el resultado. En 2 dimensiones se aprecian agrupaciones por dígito, aunque con solapamiento (por ejemplo, entre 3, 5 y 8), lo cual es esperable al comprimir 64 variables en 2.

Tabla 3

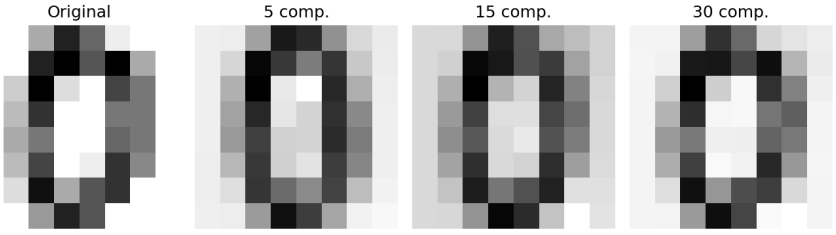
K-means (k = 10) sobre Digits con datos originales y reducidos

Entrada	Variables	Silueta	ARI
Original	64	0,182	0,667
SVD truncada	20	0,212	0,666

Reducir de 64 a 20 variables con SVD mantuvo el ARI (0,667 vs. 0,666) y mejoró ligeramente la silueta (0,182 → 0,212), con un 69 % menos de dimensiones. Esto sugiere que las componentes descartadas aportaban sobre todo ruido y que la reducción hace el clustering más barato sin perder calidad.

Figura 5

Reconstrucción de un dígito con 5, 15 y 30 componentes principales



La reconstrucción confirma la compresión: a medida que aumentan las componentes la imagen se parece cada vez más al original, y con 30 es casi idéntica.

Conclusiones

(1) Estandarizar las variables fue indispensable en Wine para que K-means y PCA no estuvieran dominados por las variables de mayor magnitud. (2) El coeficiente de silueta identificó correctamente $k = 3$, y K-means (ARI 0,897) superó al clustering jerárquico de Ward (ARI 0,790) en este conjunto, mientras que el dendrograma aportó una visión jerárquica complementaria. (3) PCA y SVD permitieron reducir la dimensionalidad con muy poca pérdida de calidad en el agrupamiento, además de habilitar visualizaciones en 2D. (4) Las métricas internas (silueta) y externas (ARI) deben leerse en conjunto: una silueta moderada no impidió una alta coincidencia con las clases reales. Como limitaciones, se trabajó con conjuntos pequeños y limpios, y las proyecciones lineales no capturan estructuras no lineales; como trabajo futuro se podrían probar DBSCAN, t-SNE o UMAP.

Repositorio de GitHub

Notebooks de Google Colab y figuras: https://github.com/Jerson09/R1-A3-S12-INFORME-DE-TRABAJO-ML-NO-SUPERVISADO

Referencias

Arthur, D., y Vassilvitskii, S. (2007). k-means++: The advantages of careful seeding. *Proceedings of the 18th Annual ACM-SIAM Symposium on Discrete Algorithms*, 1027–1035.

Halko, N., Martinsson, P.-G., y Tropp, J. A. (2011). Finding structure with randomness: Probabilistic algorithms for constructing approximate matrix decompositions. *SIAM Review, 53*(2), 217–288. https://doi.org/10.1137/090771806

Hastie, T., Tibshirani, R., y Friedman, J. (2009). *The elements of statistical learning: Data mining, inference, and prediction* (2.ª ed.). Springer.

Hubert, L., y Arabie, P. (1985). Comparing partitions. *Journal of Classification, 2*(1), 193–218. https://doi.org/10.1007/BF01908075

Hunter, J. D. (2007). Matplotlib: A 2D graphics environment. *Computing in Science & Engineering, 9*(3), 90–95. https://doi.org/10.1109/MCSE.2007.55

Jolliffe, I. T., y Cadima, J. (2016). Principal component analysis: A review and recent developments. *Philosophical Transactions of the Royal Society A, 374*(2065), 20150202. https://doi.org/10.1098/rsta.2015.0202

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., y Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research, 12*, 2825–2830.

Rousseeuw, P. J. (1987). Silhouettes: A graphical aid to the interpretation and validation of cluster analysis. *Journal of Computational and Applied Mathematics, 20*, 53–65. https://doi.org/10.1016/0377-0427(87)90125-7

Ward, J. H. (1963). Hierarchical grouping to optimize an objective function. *Journal of the American Statistical Association, 58*(301), 236–244. https://doi.org/10.1080/01621459.1963.10500845